

Просмотрите обсуждения, статистику и профили авторов для этой публикации по адресу: <https://www.researchgate.net/publication/329486303>

Система контроля тяги, основанная на коэволюционном обучении в нейронной сети с импульсами (SNN)

Документ конференции · Июль 2018

ЦИТАТЫ

0

ЧИТАЕТ

112

3 автора:



Хавьер Перес Фернандес

Университет Малаги

12 ПУБЛИКАЦИИ 55 ЦИТАТЫ

[СМОТРЕТЬ ПРОФИЛЬ](#)



Хуан Кабрера

Университет Малаги

69 ПУБЛИКАЦИИ 940 ЦИТАТЫ

[СМОТРЕТЬ ПРОФИЛЬ](#)



Хуан Кастильо

Университет Малаги

36 ПУБЛИКАЦИИ 423 ЦИТАТЫ

[СМОТРЕТЬ ПРОФИЛЬ](#)

Некоторые из авторов этой публикации также работают над этими родственными проектами:



Desarrollo de un sistema avanzado de control de tracción y frenada para motocicleta [Посмотреть проект](#)



806 / 31.4559 ORTHOAPNEA, SL [Посмотреть проект](#)

Система контроля тяги, основанная на коэволюционной Обучение в нейронной сети с импульсами (SNN)

Хавьер Перес, Хуан А. Кабрера и Хуан Х. Кастильо

Кафедра машиностроения Университета

Малаги, Малага, Испания

Эл. адрес : javierperez@uma.es

Система контроля тяги (TCS) разработана и обучена для различных дорожных условий с коэволюционным обучением на основе генетических алгоритмов. Общие TCS не учитывают вариации и колебания, возникающие при переходе между поверхностями, определяя логику управления, которая сильно зависит от точности дороги и оценок скорости. Для решения этой проблемы используется процесс коэволюционного обучения. Предлагаемая процедура обучает алгоритм управления, основанный на нейронной сети с пиками, на различных поверхностях и переходах поверхностей в поисках наилучшего сценария. Таким образом, получается алгоритм управления с хорошей динамической реакцией на постоянные и меняющиеся дороги. Этот контроль делает систему стабильной, когда оценка дороги задерживается или нестабильна, устраняя общий недостаток, вызванный шумом датчика или задержками вычислений.

Ключевые слова: коэволюция, противобуксовочная система, нейронная сеть с импульсами.

Управление трансмиссией и управление энергопотреблением

1. ВВЕДЕНИЕ

Системы активной безопасности в транспортных средствах являются важным инструментом снижения аварийности за счет контроля пробуксовки колес или повышения устойчивости. Системы контроля тяги играют важную роль во время ускорений, контролируя пробуксовку и поддерживая контакт колеса с асфальтом для улучшения управляемости автомобиля. Изменение типа дороги может вызвать нежелательный отклик из-за кратковременных колебаний. Обычно алгоритмы управления работают лучше при постоянном соблюдении условий движения по дороге. Однако колебания наблюдаются при переходах между разными поверхностями. Это событие может вызвать аварию из-за потери тяги или снизить производительность автомобиля. В мотоциклах TCS встречаются реже из-за сложности мотоциклетной динамики и удорожания. Обычно управляющими сигналами TCS являются крутящий момент задней шины, входной дроссель и / или частота вращения колеса / двигателя. Эти параметры необходимо измерить или оценить на мотоциклах с двигателем внутреннего сгорания. Однако в электрическом мотоцикле, их легко получить с высокой степенью точности. Следовательно, в этих автомобилях TCS - это, по сути, только проблема программного обеспечения. В данной работе описан алгоритм управления пробуксовкой электромоторов. Среди различных методов, используемых в алгоритмах TCS, - порог скольжения, PID, скользящее управление, нечеткая логика и нейронная сеть. Порог скольжения использует простой алгоритм [1], в котором в зависимости от типа дороги устанавливается максимальный коэффициент скольжения, который позволяет TCS отключать питание колес. Основная проблема этого контроля - зависимость от оценки дороги, что еще больше ухудшает контроль при переходах из-за недостаточной точности и задержек оценки. ПИД-регуляторы [2] также сильно зависят от оценки, но

работают лучше благодаря временной зависимости параметров производной и интегратора.

Скользкое управление, [3], [4], отслеживает управляющую переменную при изменении во времени, улучшая динамический отклик с той же зависимостью оценки, что и PID. Fuzzy Logic знакомит с опытом эксперта [5]. Алгоритм управления также требует дополнительной информации о текущем состоянии транспортного средства, например о положении дроссельной заслонки или крутящем моменте на ведущих колесах. Следовательно, в этой логике оценочные переменные имеют меньшее значение.

Слияние ПИД-регулятора и нечеткого контроллера увеличивает возможности управления, предлагая лучший отклик, но логика все еще недостаточна для управления дорожными сдвигами [6]. Кроме того, управление нейронной сетью [7] способно обрабатывать изменения дорожных условий из-за их пластичности, которая адаптирует управление во время переходов. Нейро-четкая комбинация также используется для определения алгоритма управления [8], [9].

При использовании контроллеров на основе нейронных сетей возникают три проблемы. Во-первых, зависимость от времени, классической искусственной нейронной сети требуется несколько отложенных входов, чтобы реагировать на быстрое изменение. Во-вторых, нейронная структура в нейронных сетях определяет возможности управления и обучения. В-третьих, процесс обучения влияет на способность адаптироваться к разным дорогам. Обучающий набор учит контроллера, как действовать на дороге, при этом трудно добиться хорошего поведения на различных поверхностях. После анализа этих проблем представлена наша реализация. Пиковые нейронные сети представлены как надежная модель реальных нейронов, встречающихся в природе. Использование этих нейронов для управления довольно широко, переводя контролирующее поведение, обнаруживаемое у людей или других животных, в инженерные проблемы управления [10], такие как самоуправление [11], робототехника [12] или биологические методы управления.

механика [13]. Другие работы сосредоточены на динамике автомобиля, [14], без учета переходных условий. В этой статье представлен импульсный контроль нейронной сети с коэволюционным обучением, который улучшает реакцию системы при внезапных изменениях дороги. SNN используют последовательности временных пиков для управления входами и выходами, что позволяет выполнять более быстрые и сложные вычисления. Коэволюционное обучение используется для обучения сети в различных ситуациях по наихудшему сценарию. После итерационного процесса полученная сеть делает управление устойчивым при переходах.

Остальная часть этой статьи организована следующим образом. В Разделе 2 определяется используемая модель мотоцикла. В разделе 3 представлена система контроля тяги. В разделе 4 описывается структура нейронной сети с импульсным управлением, а в разделе 5 подробно описывается процесс коэволюционного обучения. В разделе 6 представлены экспериментальные результаты. Выводы и будущие работы обсуждаются в разделе 7.

2. МОДЕЛЬ МОТОЦИКЛА.

Электрический мотоцикл смоделирован в © BikeSim и © Matlab. В модели используется карта крутящий момент-частота вращения для воспроизведения характеристик электродвигателя в процессах тяги и рекуперативного торможения.




Рис. 1. Карта крутящий момент-частота вращения двигателя для дроссельной заслонки и значения регенерации

3. ТЯГА РАБОТА КОНТРОЛЬ СИСТЕМА

Работа TCS направлена на поддержание оптимального пробуксовки колес для каждого типа дороги. Это обеспечивает максимальный коэффициент сцепления с дорогой. Пробуксовка заднего колеса рассчитывается по уравнению 1.

$$\mu_{\text{зад}} \text{ равно } 1 - \frac{V_{\text{Икс}}}{-r p_r} \quad (1)$$

Где, ω_r скорость заднего колеса, p_r - радиус колеса и $V_{\text{Икс}}$ скорость автомобиля. Скорость автомобиля считается известной в данной работе. Предыдущие исследования показывают, что для оценки скорости можно использовать GPS, EKF или их комбинацию. В этом документе используются данные о скорости автомобиля, предоставленные BikeSim.

Как только заднее скольжение было получено, алгоритму управления требуется только оптимальное скольжение, чтобы установить цель. Расчет оптимального пробуксовки приносит еще один уровень сложности из-за зависимости от типа дороги. Нечеткое

оценка, разработанная нашей исследовательской группой в [5], используется для получения оптимального скольжения.

4. КОНТРОЛЬ ШИПЫ НЕЙРОННОЙ СЕТЬ

В этом разделе рассматривается структура алгоритма управления на основе нейронных сетей с пиками. Определяются нейрон, модель синапса и расположение входных и выходных нейронов.

а. Модель нейрона

Используется нейрон Ижикевича. Эта модель точно воспроизводит реальный нейрон, не считая низких требований к вычислениям. Два дифференциальных уравнения имитируют мембранный потенциал v и величину восстановления нейрона. Порог срабатывания нейрона устанавливается уравнением 4, сбрасывающим как мембранный потенциал v , так и восстановление u .

$$\frac{dv}{dt} \text{ знак равно } 0,94v^2 + 5v + 140 - \tau v + \gamma(t) \quad (2)$$

$$\frac{du}{dt} \text{ знак равно } a(bv - \tau u) \quad (3)$$

$$\begin{aligned} & - V - C \\ \text{Если } v - 30 \text{ тогда } & - \tau u - \tau v + d \end{aligned} \quad (4)$$

В этой системе уравнений тип нейрона определяется параметрами a , b , v , g как определяет Ижикевич, создавая разные типы поведения нейронов в зависимости от входного тока $\gamma(t)$ из предыдущих синапсов.

б. Модель синапса

Модель синапса определяет, как нейронная сеть обучается и превращается в оптимальную логику управления. По этой причине модель должна точно отображать синапс в реальной природе. Межсоединения нейронов выполняют сложный процесс, но его можно упростить следующим образом.

$$\gamma(t) \text{ знак равно } \sum_j w_{ij} (T - T_{\text{шип}}) \quad (5)$$

$$\begin{aligned} & - (T - T_{\text{шип}}) - \frac{T - T_{\text{шип}}}{-0,} e^{-\frac{T - T_{\text{шип}}}{-0,}} \\ & \text{Если } T - T_{\text{шип}} \end{aligned} \quad (6)$$

Где $I(t)$ - выходные токи, которые текут к постсинаптическим нейронам в результате синхронизации входных импульсов ($t_{\text{шип}}$) и вес синапса w_{ij} которые контролируют силу соединения. Как и в природе, выходной ток со временем уменьшается. τ в экспоненциальном затухании, управляемом t .

с. Структура нейронной сети

Нейронная структура зависит от ее применения. Один или несколько скрытых слоев используются, когда сеть предназначена для обнаружения паттерна или распознавания типа поведения. Этот

Кстати, производительность сети увеличивается, но также и ее сложность. Однако в управляющих приложениях сеть должна быть как можно более простой, чтобы быстро реагировать на изменения ввода. По этой причине предлагаемая сеть (рис. 2) имеет только два слоя: входной слой с тремя нейронами и выходной слой с двумя нейронами.




Рис.2 Структура нейронной сети

Поскольку пикирующие нейроны работают с пиками, необходим этап кодирования и декодирования. К этому процессу следует добавить минимально возможную задержку. Используется входной код, аналогичный этапу фаззификации с гауссовыми звонками. Кроме того, используется выходной код, аналогичный модели двух антагонистических мышц [10]. Таким образом, алгоритм пытается имитировать естественные управляющие структуры, когда несколько нейронов быстро реагируют на заданный вход. Желаемое поведение поддерживает выход, пока ошибка входа равна нулю, увеличивая выход, когда вход низкий, и наоборот. Вес в синаптических связях способен возбуждать или тормозить постсинаптический нейрон в зависимости от знака. На рис. 2 запрещенные связи изображены кружками, а возбуждающие - стрелками.




Рис.3 Схема управляющей нейронной сети

Вся схема (рис. 3) смоделирована в © Simulink и BikeSim. Испытываются разные дороги и методы обучения. Результаты показаны в разделах 5 и 6.

5. СОЗВОЛЮЦИОННОЕ ОБУЧЕНИЕ

Процесс обучения улучшает эффективность управления за счет обучения системы в различных условиях. Основная цель - получить алгоритм управления, способный оптимально работать на разных дорогах и при изменении дороги во время ускорения. Отношение между теоретическим расстоянием и полученным расстоянием используется для проведения сравнений.

а. Целевая функция

Для вычисления теоретического расстояния используется продольное уравнение мотоцикла. Аэродинамическая сила $F_{aэро}$ и сила сопротивления качению $F_{грунт}$ не рассматриваются.

$$F_{фрик} = F_{aэро} - F_{грунт} \quad \text{знак равно} \quad m \cdot a \quad \text{знак равно} \quad -F_z \cdot \mu \quad \text{знак равно} \quad -k_p \cdot m \cdot g \quad (7)$$

После замены продольной силы трения $F_{фрик}$ по уравнению трения колеса $F_{фрик} = \mu \cdot F_z$, где μ - коэффициент трения, F_z - вертикальная нагрузка на ведущее колесо. Фракция k_p от общей массы m принимается вертикальная нагрузка на заднее колесо. Таким образом, максимально возможное ускорение может быть рассчитано из уравнения 8 и. Уравнение движения с постоянным ускорением дает теоретическое максимальное расстояние 9.

$$a \cdot \text{знак равно} \quad -g \cdot k_p \quad (8)$$

$$m \cdot T_1 \cdot \text{знак равно} \quad \frac{1}{2} \cdot a \cdot T_1^2 + \frac{1}{2} \cdot a \cdot (T_2 - T_1)^2 \quad (9)$$




Рис. 4. Определение теста

Введен переменный тест, чтобы получить стабильный контроль при изменении дороги. Фиг.4 показывает, что воспроизводит этот факт. Коэффициент трения μ_1 используется для первого участка дороги, а коэффициент трения μ_2 для второго участка дороги. Для этого теста общая ошибка 10 - это квадратичная ошибка двух участков дороги 11 и 12:

$$e(-1, T_1, -2,) = \frac{M}{m_1} \cdot T_1^2 - \frac{M}{m_2} \cdot T_2^2 \quad (10)$$

$$m \cdot T_1 \cdot \text{знак равно} \quad \frac{1}{2} \cdot V_{1, макс} \cdot (T_1 - T_{в этом})^2 + g \cdot k_p \cdot (T_1 - T_{в этом})^2 \quad (11)$$

$$m \cdot T_2 \cdot \text{знак равно} \quad \frac{1}{2} \cdot V_{2, макс} \cdot (T_2 - T_{конеч} - T_1)^2 + g \cdot k_p \cdot (T_2 - T_{конеч} - T_1)^2 \quad (12)$$

Где m_1 и m_2 - пройденное расстояние для каждого контроллера, а mt_1 и mt_2 - теоретическое максимальное расстояние. Процедура обучения пытается минимизировать эту ошибку.

б. Процедура обучения

Козволюционное обучение (рис. 5) реализовано как алгоритм обучения для уменьшения ошибок в процессе обучения с учителем. Данный набор входов и выходов используется для обучения сети, а другой набор используется для проверки процесса обучения. В управляющем приложении нейронный алгоритм обучается в замкнутом цикле, где входными данными являются дороги или вариации дорог, а выходными данными - цель.

функция. TCS направлен на уменьшение ошибки скольжения, которая приводит к увеличению пройденного расстояния.

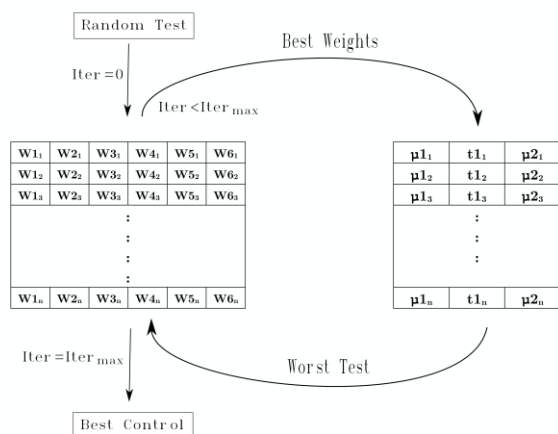


Рис.5 Процесс обучения

В процессе совместной эволюции два или более видов взаимно влияют на эволюцию друг друга. В этой статье для эволюции вида используются генетические алгоритмы совместной эволюции.

Наша нейронная сеть - это основной вид. Другой - состояние дороги, основанное на целевой функции. Оба вида соревнуются во взаимодействии жертвы и хищника. Добыча - это нейронная сеть, которая развивается для данного хищника (дорожные условия), пока он не станет непобедимым, с оптимальным результатом для этой комбинации дорог. Затем хищник для данной жертвы (оптимальный алгоритм) эволюционирует и побеждает ее, находя дорожные условия, в которых он проявляет наихудшие результаты, таким образом побеждая жертву.

Эта процедура эволюции повторяется итеративно. Наша предлагаемая структура имеет 3 входных нейрона и 2 выходных нейрона, поэтому необходимо установить в общей сложности 6 весов. Остальные параметры - это тип нейрона, который фиксируется во время моделирования. Состояние дороги, представленное на рис. 4, определяется тремя параметрами (μ_1 , t_1 , μ_2). Все эти параметры выбираются алгоритмом для получения наилучших результатов, как будет показано в следующем разделе.

6. РЕЗУЛЬТАТЫ

Наконец, чтобы продемонстрировать возможности нашего элемента управления, моделируются различные дорожные испытания (таблицы 1 и 2). Процесс обучения, основанный на коэволюции, сравнивается с генетическим алгоритмом, обученным для конкретной дороги. Генетический алгоритм, обученный для различных дорожных условий, не используется из-за гораздо больших вычислительных усилий, необходимых для получения аналогичной ошибки. Контроллер с нечеткой логикой также используется для сравнения управления с другим подходом.

Для оценки возможностей контроллера нейронной сети используются два основных моделирования. Сначала на рис. 7 показан тест постоянного состояния дороги. Затем на рис. 8 выполняется моделирование переменного состояния дороги. С одной стороны, результаты для постоянного состояния дороги очевидны. Контроллеры нейронной сети, обученные с помощью генетических алгоритмов, лучше работают на дорогах, где они были обучены. Однако их характеристики хуже в других дорожных условиях. Нечеткая логика дает хорошие результаты на всех дорогах. Наконец, алгоритм, обученный с помощью коэволюции, дает лучший общий результат.


Таблица 1 Значение ошибки для постоянного дорожного испытания

Дорога	$\mu = 0,2$	$\mu = 0,4$	$\mu = 0,6$	$\mu = 0,8$	$\mu = 1$	Σe
Цепь AG $\mu = 0,2$	1,0000	0,8379	0,8267	0,7171	0,6237	4,0055
Цепь AG $\mu = 0,4$	0,9793	1,0000	0,8719	0,8685	0,7360	4,4556
Цепь AG $\mu = 0,6$	0,9183	0,8268	1,0000	0,7875	0,6276	4,1601
Цепь AG $\mu = 0,8$	0,9666	0,8619	0,9220	1,0000	0,8407	4,5911
Цепь AG $\mu = 1$	0,9017	0,7667	0,9090	0,8884	1,0000	4,4658
Козволюционный	0,9540	0,8851	0,9428	0,8639	0,9705	4,6162
Нечеткая логика	0,9260	0,8314	0,9203	0,7885	0,6417	4,1079


Таблица 2 Значение ошибки для переменного дорожного испытания ($t_1 = 1,5$ с)

Дорога	$\mu = 0,2$ $\mu = 0,6$	$\mu = 0,6$ $\mu = 0,2$	$\mu = 1$ $\mu = 0,4$	$\mu = 0,4$ $\mu = 1$	$\mu = 0,6$ $\mu = 0,4$	$\mu = 0,4$ $\mu = 0,6$	Σe
Цепь AG $\mu = 0,2$	0,8177	0,7705	0,6337	0,9391	0,8092	0,8966	4,8668
Цепь AG $\mu = 0,4$	1,0000	0,8776	0,7468	0,8847	0,8808	1,0000	5,3898
Цепь AG $\mu = 0,6$	0,9250	1,0000	0,6721	0,9677	1,0000	0,9504	5,5152
Цепь AG $\mu = 0,8$	0,8591	0,9112	0,8415	0,8480	0,9053	0,9328	5,2979
Цепь AG $\mu = 1$	0,8533	0,8449	1,0000	1,0000	0,8554	0,8628	5,4164
Козволюционный	0,9292	0,9359	0,9689	0,9084	0,9481	0,9444	5,6349
Нечеткая логика	0,9440	0,9965	0,6840	0,7431	0,9727	0,8737	5,2141

а. Постоянная дорога




а)




б)

Рис. 7.1 Постоянные дорожные испытания с высоким сцеплением ($\mu_1 = \mu_2 = 0,8$)




а)




б)

Рис. 7.2 Постоянные дорожные испытания со средней адгезией ($\mu_1 = \mu_2 = 0,6$)




а)




б)

Рис. 7.3 Постоянные дорожные испытания с низким сцеплением ($\mu_1 = \mu_2 = 0,4$)

б. Переменная дорога




а)




б)

Рис. 8.1 Переменное дорожное испытание со значениями сцепления от низкого до высокого ($\mu_1 = 0,4 \rightarrow \mu_2 = 0,8$)



а)



б)

Рис. 8.1 Дорожные испытания с переменным сцеплением от высокого до низкого ($\mu_1 = 0,8 \rightarrow \mu_2 = 0,4$)

* а) Скорость транспортного средства и колеса для контроллеров с низким и высоким сцеплением, обученных с помощью AG, по сравнению с коэволюционным контроллером. б) Расстояние в метрах для каждого ускорения.

Аналогичные выводы можно сделать, когда в процессе моделирования происходит изменение дороги. В этом случае производительность контроллеров, обученных ГА, сильно зависит от исходной поверхности. Опять же, нечеткая логика дает хорошие результаты во всех случаях. Наконец, коэволюция дает наилучшие общие характеристики.




Рис. 6. Процесс обучения.

После нескольких итераций алгоритм совместной эволюции имеет наименьшее значение для всех различных дорожных условий (рис. 6). Также показана ошибка управления, обученного с помощью ГА для конкретного типа дороги. Эффективность метода обучения, основанного на коэволюции, выше, чем у ГА. Конечная ошибка при использовании коэволюции меньше при тех же объемах вычислений и времени выполнения.

7. ЗАКЛЮЧЕНИЕ

В этой работе представлена система контроля тяги на основе нейронных сетей Spiking. Для обучения нейронной сети используются генетические и коэволюционные алгоритмы. Процесс обучения, основанный на коэволюции, сокращает вычислительное время тренировочного процесса. Обычные TCS не работают оптимально во всех дорожных условиях и, особенно, когда во время активации изменяется сцепление с дорогой. Предлагаемый контроллер имеет лучшую общую производительность не только в условиях постоянного соблюдения режима, но также и при изменении соблюдения режима во время теста.

В будущих работах будут проведены испытания электровелосипеда на реальных дорогах.

ПОДТВЕРЖДЕНИЕ

Работа частично поддержана Министерством инновационных наук Испании в рамках гранта TRA2015-67920-R.

ИСПОЛЬЗОВАННАЯ ЛИТЕРАТУРА

- [1] Ю. Ифань, З. Цзянь, З. Ян и В. Цзянь, «Исследование и испытание системы регулирования тягового усилия распределенных электромобилей», № 2. С. 277–280, 2017.
- [2] М. Ваези, ESJ Хесам и С. Анвар, «ИМС-ПИД-регулятор тяги для автомобиля посредством регулирования крутящего момента двигателя», Труды Международной конференции IEEE по промышленным технологиям, т. 2015-июнь, нет. Июнь, 2015. С. 296–302.
- [3] Я. Тан, Х. Чжан, Д. Чжан, Г. Чжао, Х. Гуань, «Конструкция регулятора скользящего режима дробного порядка для антиблокировочных систем», Нейровычисления, т. 111. С. 122–130, 2013.
- [4] С. Раджендран, С. Сперджен, Г. Цампардукас, и Р. Хэмпсон, «Регулируемое во времени управление скользящим режимом для управления ABS электромобилем», IFAC-PapersOnLine, vol. 50, нет. 1. С. 8820–8825, 2017.
- [5] Дж. А. Кабрера, Дж. Дж. Кастильо, Э. Карабиас и А. Ортис, «Эволюционная оптимизация системы контроля тяги мотоцикла на основе нечеткой логики», IEEE Transactions on Fuzzy Systems, vol. 23, нет. 5. С. 1594–1607, 2015.
- [6] Х. Дахмани, О. Пар, А.Е. Хаджаджи, «Traction Система управления с использованием нечеткого представления модели транспортного средства // Управление. 1. С. 5712–5717, 2015.
- [7] Х. Ван, К. Сюэ, В. А. Грувер и В.С. Vsa, «Управление параллельной нейронной сетью», стр. 2934–2938, 1995 г.
- [8] Ю.-э. Мао, Ю. Чжан, Т. Лю, «Скольжение контроллер режимов для автомобильной ABS на основе нечеткой нейронной сети», Шестая международная конференция по естественным вычислениям, 2010 г., No. Incp, стр. 1410–1413, 2010.
- [9] А.В. Топалов, Я. Ониз, Э. Каякан, О. Кайнак, «Нейронечеткое управление антиблокировочной тормозной системой с использованием алгоритма инкрементального обучения в скользящем режиме», Нейрокомпьютинг, т. 74, нет. 11. С. 1883–1893, 2011.
- [10] Х. Перес, Дж. А. Кабрера, Дж. Дж. Кастильо и Дж. М. Веласко, «Нейронная сеть на основе биологических импульсов для управления нелинейными системами», Нейронные сети, т. 104, стр. 15 - 25, 2018
- [11] Дж. Кайзер, JCV Tieck, К. Хубшнайдер, П. Вольф, М. Вебер, М. Хофф, А. Фридрих, К. Войтасик, А. Робеннау и Р. Колхас, «К структуре для сквозного управления моделируемым транспортным средством с помощью нейронных сетей с импульсными сигналами», стр. 127–134, 2016.
- [12] Т.С. Клоусон, член С., Феррари С., С. Член С.Б. Фуллер, Р.Дж. Вуд и член С., «Нейронная сеть с импульсами (SNN), управляющая машущим роботом размером с насекомое», № Cdc, стр. 3381–3388, 2016.
- [13] М. Hulea и CF Caruntu, «Нейронная сеть для управления искусственными мышцами гуманоидной руки-робота», 18-я Международная конференция по теории систем, управлению и вычислениям, 2014 г., ICSTCC, 2014 г., стр. 163–168, 2014 г.
- [14] Я. Ониз, А.К. Арас, О. Кайнак, «Контроль антиблокировочной тормозной системы с использованием нейронных сетей с импульсными сигналами», Материалы IECON (Конференция по промышленной электронике), стр. 3422–3427, 2013.